

ICCV 2025 후기

ICCV 2025
Review

- Hawaii, Honolulu
- 7500명 ↑ 참가자
- Paper accept rate : 24% (2,698/11,239) → 2019년 대비 제출편수 160% 증가 (2019년엔 1,062/4,303 : 24% 동일)



김범준


학회장 분위기

- 모두가 아침 식사를 같이 → 옆사람하고 자연스럽게 말을 하게 되는 계기
- 외국인들은 튜토리얼/워크숍을 되게 열심히 참여하는 분위기 (핫한 VLM, VLA 분야)
- Poster 발표는 생각과 다른 분위기 (질문 << 그 사람을 만나러 온 느낌?) / 반면 Oral은 순수 질문 위주





기업 부스 분위기

- 메인 스폰서(구글, 메타, 텐센트)만 제품 홍보 조금 나머지는 모두 구직의 장
- 학회 등록시 작성하는 정보 → QR로 확인가능 (모두가 본인 CV, 포폴을 올려두는 듯..)
- Poster에도 많은 학생들이 해외 Internship, PhD 등을 위한 QR코드



- VLM + Autonomous Driving / Multi-modal(LLM) Autonomous Driving 다수
 - [Hints of Prompt: Enhancing Visual Representation for Multimodal LLMs in Autonomous Driving](#)
 - [Are VLMs Ready for Autonomous Driving? An Empirical Study from the Reliability, Data and Metric Perspectives](#)
 - [AdvDreamer Unveils: Are Vision-Language Models Truly Ready for Real-World 3D Variations?](#)
 - [DistillDrive: End-to-End Multi-Mode Autonomous Driving Distillation by Isomorphic Hetero-Source Planning Model](#)



Highlight

- Tesla AI / Auto pilot Team Vice president
- CVPR 2023에서 모델 구조 및 3D occupancy prediction을 발표했던 전례
- ICCV 에서도 Tesla 모델에 대해 소개해주는 발표 세션 진행

ICCV 2025 Workshop on Distillation of Foundation Models for Autonomous Driving

Oct 20, 2025, Honolulu, Hawaii

Keynote Speakers



Kratharth Goel

Waymo



Ashok Elluswamy

Tesla



Jose Alvarez

NVIDIA

Ashok Elluswamy

VP - Autopilot / AI Software at Tesla



Tesla

11년 10개월

Vice President - AI Software

정규직

2024년 10월 - 현재 · 1년 1개월

Palo Alto, California, United States · 대면근무

Anything and everything required to get self-driving 4-wheeled robots widely.

Director - Autopilot Software

2019년 5월 - 2024년 10월 · 5년 6개월

Palo Alto, CA

Leading the autonomy software team for the Tesla Autopilot.

...

Senior Staff Software Engineer - Autopilot

2017년 9월 - 2019년 4월 · 1년 8개월

Worked on geometric scene understanding to significantly improve the performance of Autopilot using fleet learning techniques.

경력 5개 모두 표시 →

Building an Autonomous Future (by Tesla Ashok Elluswamy)

ICCV 2025
Review


- Tesla 기술 현황
 - 공장에서 출고하여 집까지 자율주행으로 배송
 - 텍사스 오스틴과 베이 에이리어에서 **로보택시** 서비스 가능 (양산차량과 동일한 스펙)



- End-to-End 구조 채택
 - 예전처럼 차량, 도로 경계선 등 개별적인 요소 perception X
 - 신경망 안에서 암묵적으로 학습될 수는 있지만 어쨌든 perception은 하지 않음
 - Input : Raw 비디오 스트림 전체 / Output : 실제 주행 행동을 결정해 출력(action)

End-to-end foundation model for all of driving

A large model, trained with tons of data, has large context, runs at 36 Hz, directly produces control actions



- 구체적인 예시 제시
 - 물 웅덩이를 피해 반대 차선으로 넘어가기 / 동물들이 길을 건널건지 말건지 의도 파악하기
→ 모두 인간에게는 쉽지만 이를 cost로 정의하려면 수많은 예외가 존재... 모두 코드로 정의 불가
 - 이런 복잡한 장면에서는 E2E가 훨씬 더 뛰어난 판단 가, 장면 전체의 맥락적 의미를 파악하기 때문
→ E2E는 인간적인 판단을 학습 가능

Codifying human values is difficult

Real-world is filled with tiny trolley problems

What's better:

1. Going over the small puddle
2. Going into the oncoming lane




<https://x.com/AEDRIVR/status/7303841783708418094>

Interface between perception & planning is ill-defined

Understanding that the last chicken is waiting to cross



Understanding that the geese aren't crossing and should go around



- **E2E의 main challenge of learning pixel → Control**
 - 첫 번째, 차원의 저주
 - 30초 분량에 20억개 토큰 분량의 정보를 처리, 단 두개의 출력 (Steering, acceleration) 만 출력
 - 테슬라는 현재 500년 분량의 데이터 존재, 학습 데이터셋 refine이 가장 key
 - but, 양보다 질이 중요 → 차량이 edge case 접하면 trigger를 걸어 수집 (by 전세계 천만대의 차량)


1. Curse of dimensionality

Extremely large context length is a minimum requirement for driving

- Input context length of 2 billion tokens:
 - 7 cameras x 36 FPS x 5 Mega pixels x 30s history / (5x5 pixel patch)
 - Navigation maps and route for next few miles
 - 100 Hz kinematic data such as speed, IMU, odometry, etc
 - 48 KHz audio data
- Output tokens:
 - Next steering and acceleration
- Need to learn the correct causal mapping of 2 billion tokens -> 2 tokens

1. Curse of dimensionality


Large data gives extreme generalization and proactive safety



- **E2E의 main challenge of learning pixel → Control**
 - 두 번째, Safety 문제 (디버깅 못하냐는 질문 항상 받음)
 - E2E라고 해도 3D occ, 3D gaussian, 타 객체등 + 자연어로 왜 그런 결정을 내렸는지 물어보기 가능
 - 이런 기능들이 모델이 세상을 어떻게 이해, 해석하는지 도움이 되고, 시스템 전체의 안정성을 줌
 - But 실제로는 control action 만 사용하지만, 위 aux 역할들이 올바른 제어를 위한 장치들

2. Interpretability and safety guarantees

Looks more like this



- E2E의 main challenge of learning pixel → Control
 - Gaussian Splatting 기술 적용 중
 - 차량은 일반적으로 직선적인 경로만 움직임 → 시점 거리 차이가 크지 않아 NeRF는 novel view에서 성능 하락이 큼
 - But 테슬라 버전의 GS는 성능이 굿 + semantic 정보 생성 가능 + 엄청나게 빠름
 - 3D 공간에 대한 디버깅 용도로 사용 중 / 차량이 너무 빨리 움직이는지 / 느리게 반응하는지 / 장애물을 잘 회피하고 있는지 등을 직관적으로 파악 가능

2. Interpretability and safety guarantees

Foundation model feedforward generates 3D gaussian splats




	Traditional GS	Tesla's generative GS
Optimization duration	~30 mins	220 ms
Initialization	3D key points	Not required
Dynamic Objects	Difficult	Yes
Novel View Quality	Low	Much higher



- E2E의 main challenge of learning pixel → Control
 - 자연어를 통해 모델과 상호 작용도 진행 중
 - 어떤 근거로 결정을 내렸는지, 어떤 사물을 가리키는 지 물어보기 가능
 - 실시간 성을 위해 항상 사용은 x, thinking을 통해 논리적 추론을 해야할때만 사용

2. Interpretability and safety guarantees

Natural language can help in “system 2 thinking” cases



- **E2E의 main challenge of learning pixel → Control**
 - 세번째, 평가(evaluation)의 어려움
 - 학습한 후 코드 상에서 action 뽑는건 잘하지만 → real-world vehicle에 적용하면 이야기 달라짐
 - 이유 궁금했는데, 안 알려준다고 생각하심...
 - 해결 하기 위해 매우매우 세밀한 평가 과정이 필요
 - 데이터에서 무작위 추출은 절대 x → 그러면 대부분 고속도로만 뽑히기에
 - 드물지만 다양한 상황이 고려된 평가 세트가 필요함 (돈을 제일 많이 썼음)
 - 그래서 World-model Simulator라는걸 구축함

3. Evaluation

The hardest of the three problems


- Even with a high quality dataset, loss isn't a sufficient indicator of performance
- Good open-loop performance does not guarantee great closed-loop results
- Many different ways to avoid a failure. Metric needs to capture this multimodality
- One way is to evaluate consequence-of-action predictions
- Needs balanced and thorough evaluation sets
- Tedious work, but secretly v.important

- E2E의 main challenge of learning pixel → Control
 - World simulator를 구축 / 상태-행동 쌍 (state-action pairs) 데이터를 inverse로 수집해 활용 함 (싸다!)
 - 과거의 state + 그때의 action을 입력 → 새로운 상태를 synthesize 해낼 수 있는 시스템
 - edge case 시뮬레이션이 목적이라 엉망인 데이터셋도 가능
 - Inverse 표현 이유 :
 - normal “이 상황에서 운전자는 어떤 행동을 했는가?”
 - This “운전자가 이 행동을 했을때 world는 어떻게 변했는가?”

3. Evaluation


Neural Network closed-loop simulator

Can be trained with cheap to collect state-action data



3. Evaluation

Can then be used as a closed loop simulator



- E2E의 main challenge of learning pixel → Control
 - World simulator로 많은 이점
 - 카메라 뷰들을 만들 수도 있고, 과거 실패 사례를 극복하기 위한 다양한 시뮬레이션 가능
 - 데이터 복제? 와 같은 이점도 가능



만든 장면 / 휠 등 세부 디테일 유지됨

3. Evaluation

Evaluate policy models on synthetic adversarial issues



다른 장면을 엮어서 데이터 증식 가능

- 테슬라는 모든 로보틱스 역량에 집중 중 (로봇 형태는 뭐든 가능)
 - 휴머노이드 로봇에도 자율주행을 동일한 방법으로 적용 / 차량과 같은 신경망 사용 !
 - action + control condition

Neural Simulation models from FSD scale to Optimus Motion conditioned robot navigation simulation



모두 생성된 영상



GT는 직선 주행 / 다른 action 했을때 여전히 잘 생성하는 모

● 받은 질문들

- planning, perception 모듈들 유지안하냐 더 이상?
 - A: (즉답 회피) 해도되고 안해도된다. E2E에서 중요한건 gradient가 종단간 흐른다는게 제일 중요
- E2E인데, 센서 데이터 처리를 위한 encoder는 사용하냐?
 - A: real-time 처리를 위해서는 센서별 인코더가 효율적일 것 같다. 그치만 센서별 데이터를 토크나이징 하는건 E2E 방식과 충돌되는 문제가 아니다. (다시 gradient 얘기)
- 월드 파운데이션 모델을 선보였는데 문제는 없는지, 또 E2E로 하면 자율주행을 위한 vector space representation을 여전히 사용중인지?
 - A: 아키텍처에 대해서는 설명하고 싶지 x, 여전히 센서의 모든 정보가 의사 결정에 사용된다는 유일한 전제고 나머지는 경험적 문제. 많은걸 시도해보고 제일 잘되는걸 사용하면 됨.
어떤 사람들은 vector space를 유지하는것을 선호하고 누군가는 아니지만, 이는 전체적인 E2E에서 봤을때 중요한 관점의 문제가 전혀 아님.
 - A: world 모델을 이용한 closed-loop가 open-loop에 비해 비용적으로 매우 이득이고, perception 같은 경우 open과 closed를 동시에 사용할 수 있어서 상충되는 문제가 아님.

- Workshop / Tutorial 모두 들을 가치가 충분하다 (어쩌면 poster보다도 더)

Tesla is the place for real-world AI & Robotics

Join us, let's make intelligent, friendly & useful robots commonplace

<https://www.tesla.com/AI>

